

AgroSearch

Relatório técnico de busca textual em manuais agrícolas

O protótipo integra pré-processamento, índice invertido e ranqueamento TF-IDF em uma aplicação Streamlit independente. O corpus contém os cinco documentos do enunciado. A busca permite inspecionar os cálculos e comparar o score acumulado com a similaridade de cosseno.

Arquitetura e pré-processamento

O arquivo `agrosearch_app.py` concentra dados, funções e interface. A normalização converte para minúsculas e remove acentos; a tokenização conserva sequências alfanuméricas. Stopwords são removidas por uma lista explícita. O PortugueseStemmer do NLTK reduz variações morfológicas e dispensa downloads adicionais. Dois checkboxes ativam ou desativam stopwords e stemming e reconstroem imediatamente o índice e o vocabulário.

O índice invertido associa cada termo aos IDs dos documentos em que ocorre, sem repetir o mesmo ID. A aba de pré-processamento mostra texto original, texto normalizado e tokens finais; as abas seguintes expõem o índice e a memória de cálculo.

Definição matemática

$TF(t,d)$ = frequência de t em d / quantidade de tokens de d .

$IDF(t) = \ln((N + 1) / (df(t) + 1)) + 1$.

$TF-IDF(t,d) = TF(t,d) \times IDF(t)$.

$Score(d,q)$ = soma de $TF-IDF(t,d)$ para termos únicos de q presentes no corpus.

A suavização mantém IDF positiva mesmo para termos presentes em todos os documentos. Repetições na consulta não multiplicam o score acumulado. No bônus, o vetor da consulta usa TF relativo e a mesma IDF do corpus; o cosseno é o produto escalar dividido pelas normas L2. Vetores nulos têm score zero.

Conformidade com a restrição

Índice invertido, TF, IDF, vetores esparsos, produto escalar e normas foram implementados com a biblioteca padrão de Python. NLTK é usado apenas para stemming; pandas e Streamlit apoiam apresentação. Não se utiliza scikit-learn, TfidfVectorizer nem um motor de busca pronto.

Resultado reproduzível

Consulta “irrigação soja”, com stopwords e stemming ativados. O ranking abaixo é calculado pelo programa; ordena-se pelo TF-IDF acumulado.

Documento	TF-IDF acumulado	Cosseno
Doc 1	0.3873	0.3935
Doc 5	0.2419	0.2407
Doc 2	0.1757	0.1605
Doc 4	0.1757	0.1605
Doc 3	0.0000	0.0000

O maior score acumulado foi de Doc 1. A soma privilegia a presença dos termos consultados e pondera o comprimento por TF relativo. O cosseno também normaliza a energia total do vetor, podendo alterar a ordem em consultas com múltiplos termos. A interface oferece as duas ordenações e sinaliza empates.

Validação e limites

Os testes verificam normalização, controles de pré-processamento, postings sem repetição e pesos calculados em um corpus pequeno com solução conhecida. Também cobrem cosseno de vetores proporcionais, vetores vazios, consulta sem correspondência e recuperação de Trichogramma no Doc 2. A interface foi exercitada com alteração dos controles e consultas vazias.

A busca lexical não infere sinônimos e pode perder distinções com stemming excessivo. A lista de stopwords é deliberadamente pequena e auditável. Termos fora do vocabulário são informados; nenhuma consulta sem correspondência produz um vencedor artificial.

Autoria e execução

Trabalho individual de Fernando Amorim Pontes Neto, responsável pela organização do projeto, implementação, validação e relatório. Não há divisão entre integrantes. Instale requirements.txt e execute **streamlit run agrosearch_app.py**. O guia LEIA-ME.md detalha o ambiente e os experimentos.

Referências: enunciado Desafio_Lab_AgroSearch.docx; NLTK SnowballStemmer, nltk.org/api/nltk.stem.snowball.html.